

SPRAWOZDANIE

Zajęcia: Matematyka Konkretna

Prowadzący: prof. dr hab. Vasyl Martsenyuk

Zadanie 7

Temat: Metoda gradientu prostego. Stosowanie do algorytmu wstecznej propagacji błędów
Wariant 13

Łukasz Pindel
Informatyka II stopień,
stacjonarne,
2 semestr,
Gr. 1

1. Polecenie:

Zadaniem do zrealizowania jest odnalezienie wartości minimalnej funkcji dwóch zmiennych $f()$ oraz zmiennych x i y metodą gradientu wraz z wizualizacją w 3D odpowiednio do określonego zadania. Można skorzystać z dowolnych bibliotek Python.

2. Wprowadzane dane:

Wariant 13 (odpowiednio wariant 1) – funkcja dwóch zmiennych

$$1. f(x, y) = (x + 3y)^3 + 2 * x, \quad x \in [1; 100], \quad y \in [1; 100]$$

Rysunek 1: Funkcja dwóch zmiennych

3. Wykorzystane komendy:

Funkcja celu (function):

$$f(x, y) = (x + 3y)^3 + 2x.$$

Ta funkcja definiuje funkcję celu, która ma być minimalizowana.

Pochodne funkcji celu (dx i dy):

$$df/dx = 3(x + 3y)^2 + 2 \text{ i } df/dy = 9(x + 3y)^2.$$

Te funkcje obliczają pochodne cząstkowe funkcji celu względem x i y .

Metoda spadku gradientu (gradient_descent):

$$\begin{aligned} x &= x - \text{learning_rate} * dx(x, y) \\ y &= y - \text{learning_rate} * dy(x, y) \\ \text{history.append}([x, y, \text{function}(x, y)]) \end{aligned}$$

Funkcja **gradient_descent()** implementuje metodę spadku gradientu. Przechodzi przez określoną liczbę iteracji i aktualizuje wartości x i y w kierunku przeciwnym do gradientu funkcji celu, pomnożonego przez stałą współczynnika uczenia. **X** aktualizuje wartość x w kierunku przeciwnym do pochodnej cząstkowej względem x , a **Y** wartość y w kierunku przeciwnym do pochodnej cząstkowej

względem y. **history.append()** zapisuje historię zmian punktów w trakcie spadku gradientu. Historia zmian jest zapisywana w postaci listy punktów.

Generowanie siatki punktów (x_vals, y_vals, X, Y, Z):

$$Z = \text{function}(X, Y)$$
$$X, Y = \text{np.meshgrid}(x_vals, y_vals)$$

Z = function(X, Y) oblicza wartości funkcji celu dla punktów X, a **np.meshgrid(x_vals, y_vals)** tworzy siatkę punktów X i Y do wygenerowania powierzchni funkcji celu

Parametry metody spadku gradientu:

$$\text{learning_rate} = 0.0001$$
$$\text{iterations} = 1000$$

Stała współczynnika uczenia (**learning_rate**) oraz liczba iteracji (**iterations**) określają parametry metody spadku gradientu.

Wykres 3D:

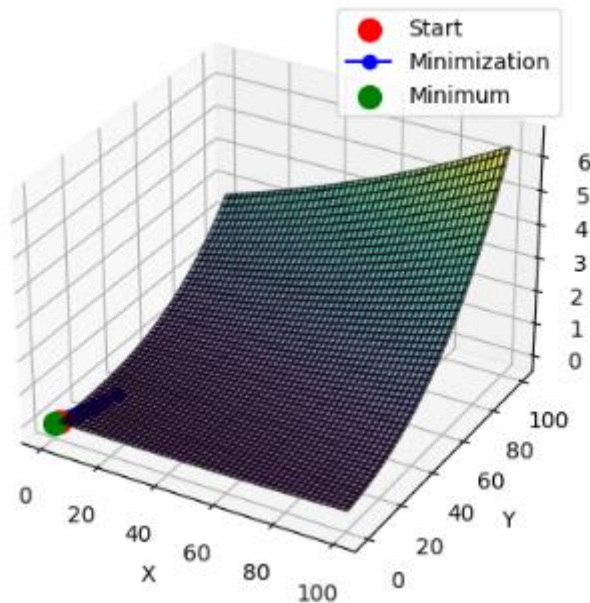
$$\text{ax.plot_surface}(X, Y, Z, \text{cmap}='viridis', \text{alpha}=0.6, \text{edgecolor}='k')$$
$$\text{ax.plot}(\text{history}[:, 0], \text{history}[:, 1], \text{history}[:, 2], \text{color}='blue', \text{marker}='o', \text{label}='Minimization')$$

ax.plot_surface(X, Y, Z, cmap='viridis', alpha=0.6, edgecolor='k') - rysuje powierzchnię funkcji celu, a funkcja **ax.plot(history[:, 0], history[:, 1], history[:, 2], color='blue', marker='o', label='Minimization')** rysuje trajektorię spadku gradientu.

Link do repozytorium:

https://github.com/denniak/MK/tree/main/MK_7

4. Wynik działania:



Rysunek 2: Otrzymany wykres funkcji dwóch zmiennych wraz z zaznaczonym minimum

5. Wnioski:

Na podstawie otrzymanego wyniku można stwierdzić, że zastosowana metoda spadku gradientu umożliwia znalezienie minimum funkcji celu. Parametry metody, takie jak stała współczynnika uczenia i liczba iteracji, odpowiednio ustawione na wartości 0.0001 oraz 1000, mają istotny wpływ na efektywność minimalizacji. Rysunek wykresu 3D wskazuje dokładnie, gdzie znajduje się minimum funkcji dwóch zmiennych – na samym początku układu współrzędnych (zaznaczone zielonym punktem), co jest kluczowym wnioskiem dla analizy tej funkcji.